RETO INTERMODULAR – BDA Y SBD

¿Dónde pueden vivir los jóvenes en Euskadi?

Situación de partida

El acceso a la vivienda se ha convertido en uno de los principales problemas de la población joven. El aumento de los precios del alquiler y de la compraventa plantea una pregunta:

¿Puede una persona joven independizarse en Euskadi con su salario?

Una entidad pública os ha encargado desarrollar un sistema de recogida, almacenamiento y análisis de datos que permita estudiar la situación de la vivienda en distintos municipios de Euskadi.

Vuestro trabajo consistirá en obtener datos reales, procesarlos y utilizarlos para responder a esta pregunta con conclusiones fundamentadas.

Objetivos del reto

Debéis desarrollar una solución utilizando **Python** que permita:

1. Recopilar datos reales sobre precios de alquiler o compraventa mediante **API y web scraping**.
2. Obtener información complementaria sobre salarios, población u otros indicadores que consideréis relevantes.
3. Almacenar en **HDFS** los datos originales obtenidos.
4. Utilizar **Apache Kafka** para simular la recepción de nuevos anuncios inmobiliarios.
5. Guardar la información en **MongoDB**.
6. Realizar la limpieza y transformación de los datos utilizando **PyMongo**.
7. Analizar la información mediante consultas y **Aggregation Pipeline** de MongoDB.
8. Presentar los resultados y justificar vuestras conclusiones.

Requisitos técnicos

BDA – Big Data Aplicado

- Extracción de datos mediante API y scraping.
- Almacenamiento de datos en HDFS.
- Creación de un productor y un consumidor Kafka utilizando Python.
- Gestión de datos en formato JSON o CSV.

SBD – Sistemas Big Data

- Diseño de una base de datos MongoDB.
- Inserción y actualización de documentos mediante PyMongo.
- Limpieza de datos incompletos, duplicados o incorrectos.
- Transformaciones mediante operaciones de MongoDB.
- Consultas y agregaciones para obtener indicadores estadísticos.

Todos los programas desarrollados deberán estar escritos en Python.

Entregables

Cada equipo entregará:

1. **Código fuente:** scripts Python organizados y documentados.
2. **Datos:** ficheros originales almacenados en HDFS y base de datos MongoDB.
3. **Arquitectura:** esquema explicativo del recorrido de los datos desde su origen hasta el análisis.
4. **Informe de resultados:** gráficos, tablas y conclusiones.
5. **Demostración:** ejecución del sistema y explicación de las decisiones técnicas.

Resultado final

El objetivo no es simplemente recopilar anuncios de viviendas.

Debéis demostrar, utilizando datos reales, qué municipios de Euskadi ofrecen mejores posibilidades de emancipación para una persona joven y explicar por qué.

Las conclusiones deberán estar respaldadas por los datos analizados.

BDA – Big Data Aplicado

RA1. Gestión de soluciones y almacenamiento

Criterio	0 puntos	3 puntos	7 puntos	10 puntos
Extracción de datos mediante Python	No obtiene datos	Obtiene datos de una fuente manualmente	Automatiza una API o scraping	Automatiza API y scraping
Almacenamiento HDFS	No almacena datos	Crea directorios	Guarda y recupera archivos	Organiza originales y procesados y demuestra su recuperación
Kafka	No funciona	Crea un tópico	Envía mensajes con productor Python	Productor y consumidor Python funcionan y procesan mensajes
Integración	No hay integración	Los componentes funcionan por separado	Integra dos o más componentes	Demuestra el flujo completo hasta MongoDB

SBD – Sistemas Big Data

RA3. Gestión, almacenamiento y consultas en MongoDB

Criterio	0 puntos	3 puntos	7 puntos	10 puntos
Modelado MongoDB	No crea la BD	Crea una colección sin estructura definida	Diseña colecciones con campos adecuados	Justifica el modelo y las relaciones entre datos
Operaciones PyMongo	No realiza operaciones	Inserta documentos	Inserta, actualiza y elimina documentos	Además, automatiza las operaciones y comprueba resultados
Consultas	No realiza consultas	Realiza consultas simples	Utiliza filtros, proyecciones y ordenaciones	Combina condiciones y consultas sobre campos anidados o arrays
Aggregation Pipeline	No utiliza agregaciones	Utiliza $match y $group	Utiliza al menos cuatro etapas diferentes	Combina varias etapas para obtener indicadores complejos

RA4. Visualización y presentación de resultados

Criterio	0 puntos	3 puntos	7 puntos	10 puntos
Gráficos	No crea gráficos	Presenta un gráfico	Presenta tres tipos de gráficos	Presenta tres tipos adecuados a los datos
Datos utilizados	No utiliza datos reales	Introduce valores manualmente	Obtiene los datos de MongoDB	Genera gráficos directamente a partir de consultas PyMongo
Presentación	No presenta resultados	Presenta gráficos sin títulos	Incluye títulos, unidades y leyendas cuando proceda	Además, los gráficos facilitan la comparación entre municipios
Interpretación	No interpreta	Describe lo que aparece	Explica tres resultados relevantes	Relaciona resultados y explica sus implicaciones