¿Puede una persona joven independizarse en Euskadi con su salario?

Datos reales · 2024-2026 · 252 municipios

En la mayoría del territorio, justo. En las capitales, no.

26,61 %

mediana del esfuerzo joven 18-34 en los 159 municipios con alquiler oficial

40/159

superan el umbral del 30 % (25,2 %)

37,7 %

Bilbao · 204 anuncios

38,2 %

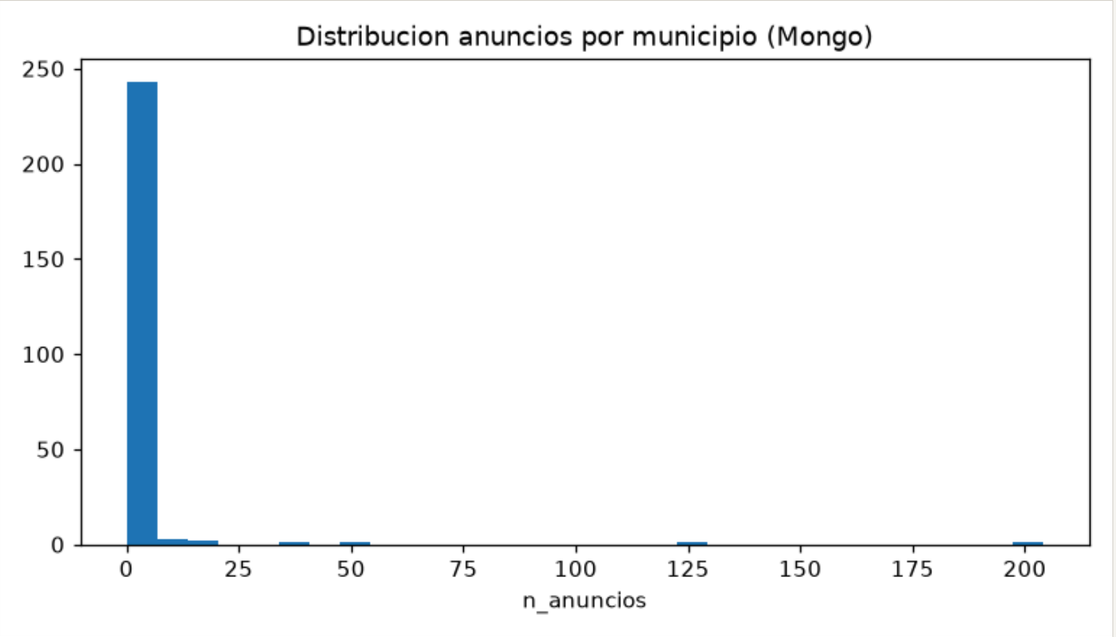
Donostia · 126 anuncios

Y en **188 municipios** no hay anuncio: «sin dato», no «asequible».

12 familias de fuentes. 41 extractores. 594 anuncios vivos.

- **356** ficheros originales: 129 CSV · 101 HTML · 61 JSON · 49 ZIP · 6 XLSX · 2 GeoJSON
- **352** canónicos en HDFS con manifest de 354 SHA
- **843 anuncios crudos → 594 vigentes**: dedup entre portales y 45 en cuarentena fuera de Euskadi
- API + scraping: Eustat, INE, Fotocasa, Pisos, Etxebide, Lanbide, Udalmap, GTFS, OSRM

La cola larga de la derecha es la razón del umbral n≥30: la mayoría de municipios tiene 0-2 anuncios.



g4 · anuncios por municipio (Mongo)

Sabemos cuánto sabemos.

159

con alquiler oficial Eustat

93

imputados IDW, solo sensibilidad

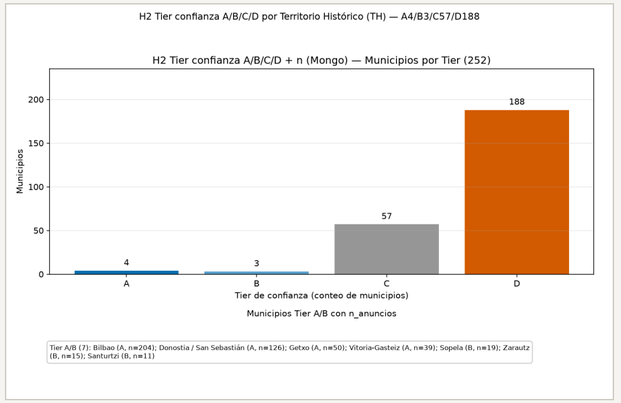
64

con anuncio (de 252)

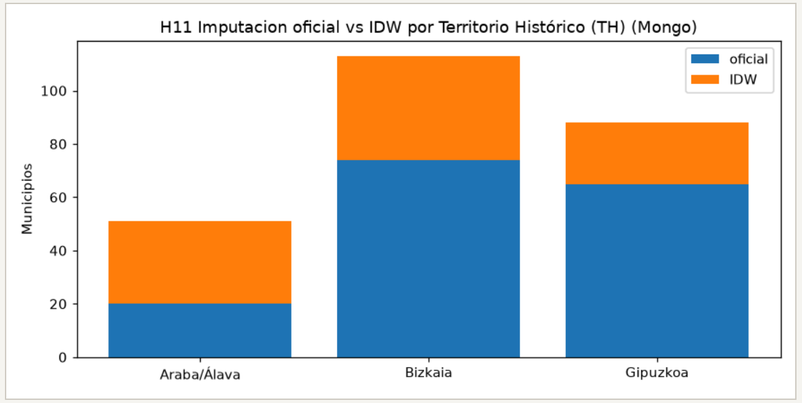
60

con precio de anuncio

Tier de confianza: **A 4 · B 3 · C 57 · D 188**.
201 habitaciones en 9 municipios · 5.040 solicitudes Etxebide · 406 promociones.



H2 · municipios por Tier (252)



H11 · oficial vs IDW por territorio

Cómo se mide.

```
esfuerzo = (alquiler mensual × 12) / renta joven estimada 18–34 × 100
```

Mediana, no media

Los alquileres tienen outliers y la media los sigue.

Umbral 30 %

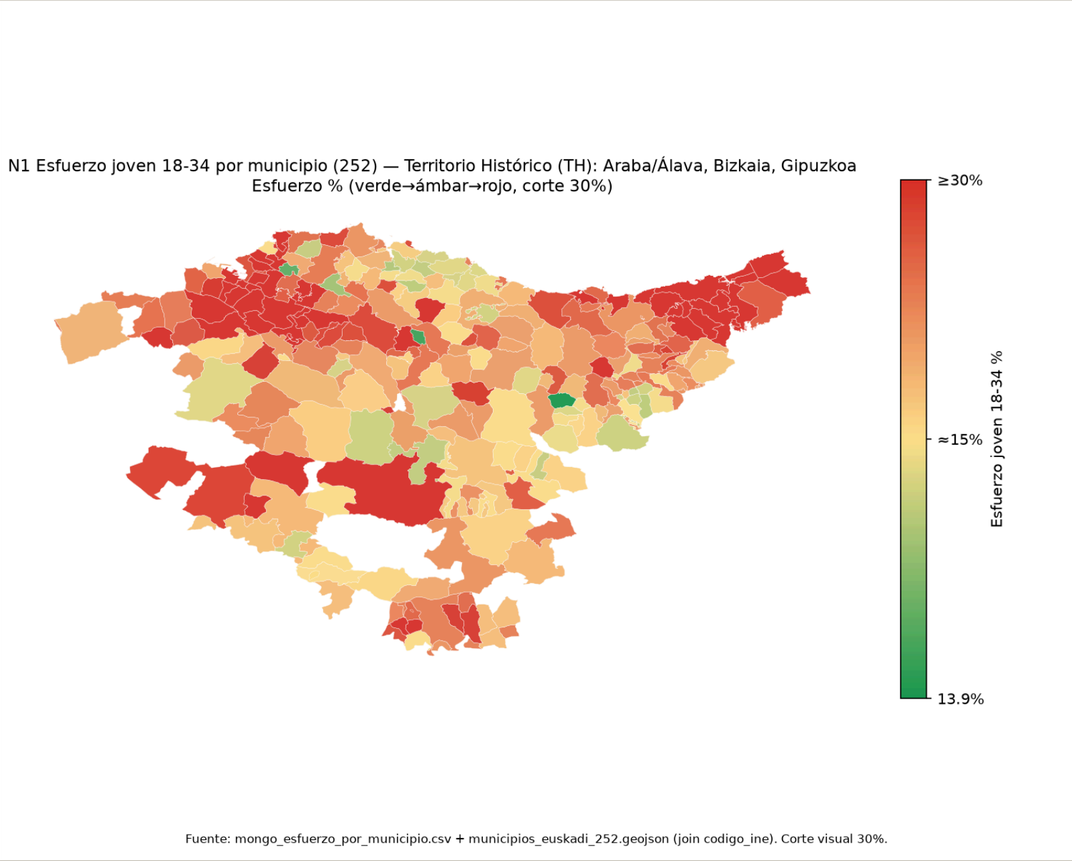
El que usa la literatura de emancipación.

18-34 es el canónico

16-29 queda legacy: 42,9 % de mediana, no comparable.

El indicador no es nuestro. Lo que aportamos es calcularlo municipal y decir dónde **no** se puede calcular.

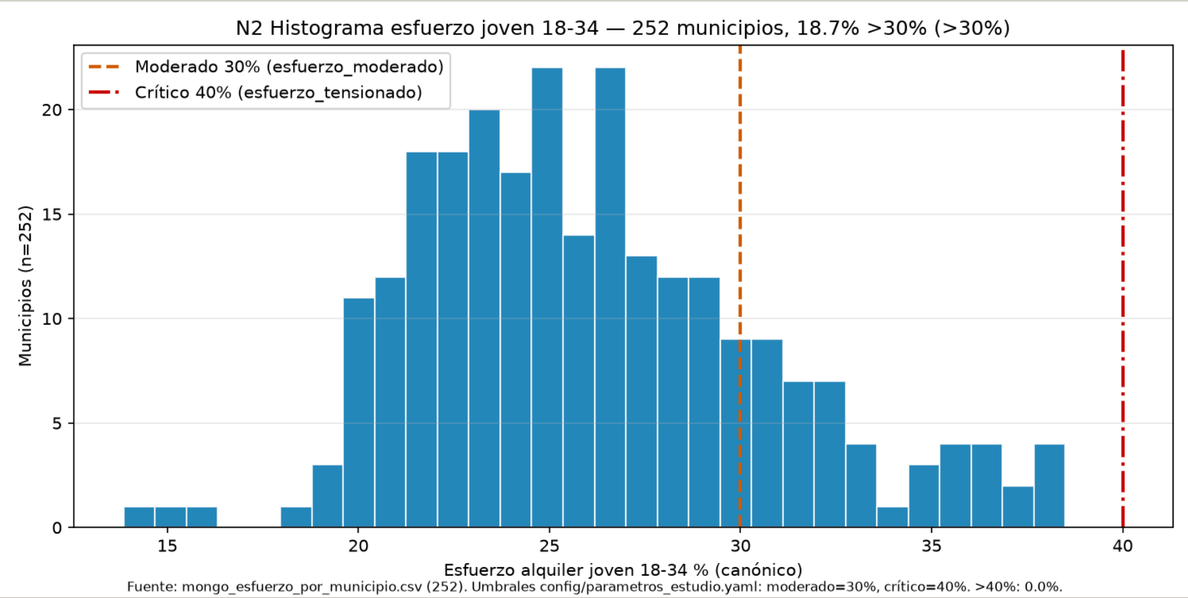
El esfuerzo tiene geografía.



esfuerzo 18–34 · 252 municipios · gris = sin dato · corte 30 %

- Capitales y corredor del Nervión, en la banda alta
- Interior de Álava y rural, por debajo del 30 %
- El gris es **sin dato**, nunca cero

No es un problema de cuatro municipios.



distribución del esfuerzo 18–34 · línea 30 %

119

< 30 %

26

30-35 %

14

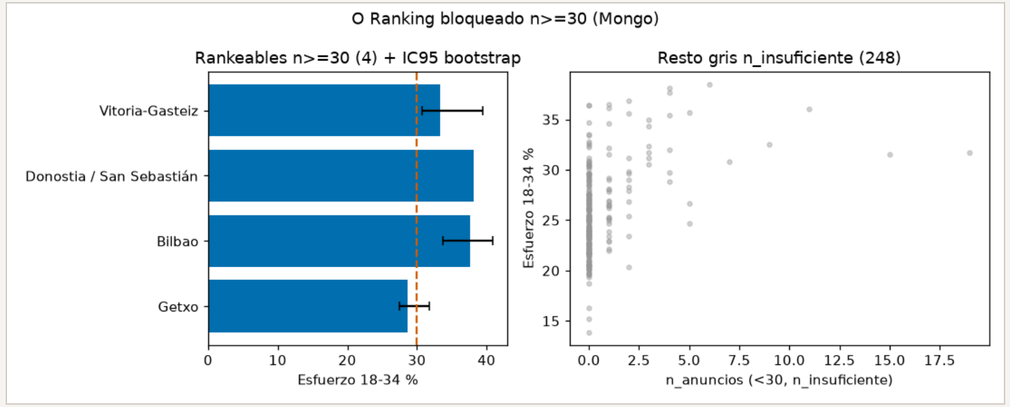
> 35 %

40 de 159 superan el 30 % (25,2 %).
Con IDW la mediana baja a 25,37 %; los que superan son 47 de 252.

Cuatro municipios resisten el escrutinio.

MUNICIPIO	N	ESFUERZO	PRECIO	PARO
Bilbao	204	37,69 %	1.704,96 €	9,71 %
Donostia	126	38,17 %	2.247,82 €	5,82 %
Getxo	50	28,60 %	1.578,21 €	6,40 %
Vitoria-Gasteiz	39	33,37 %	1.408,08 €	8,89 %

Getxo vs Vitoria: **11 anuncios** de diferencia. Sin ranking firme 3º/4º.
Barakaldo: 38,50 % con **n=6**.

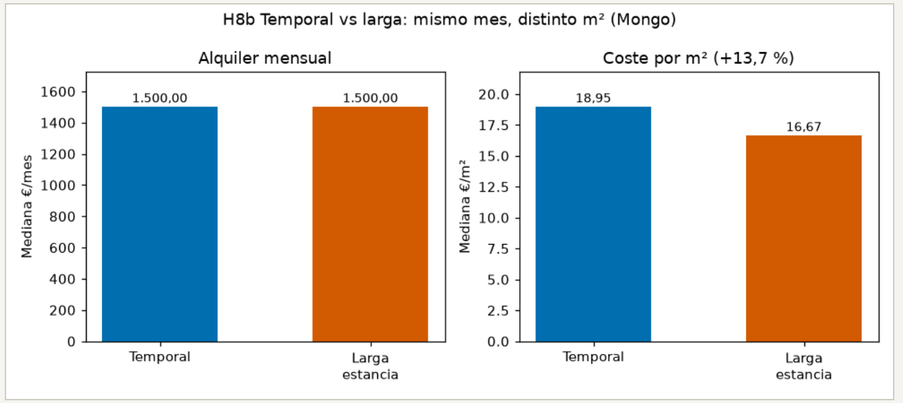


O · ranking bloqueado n≥30 e IC bootstrap

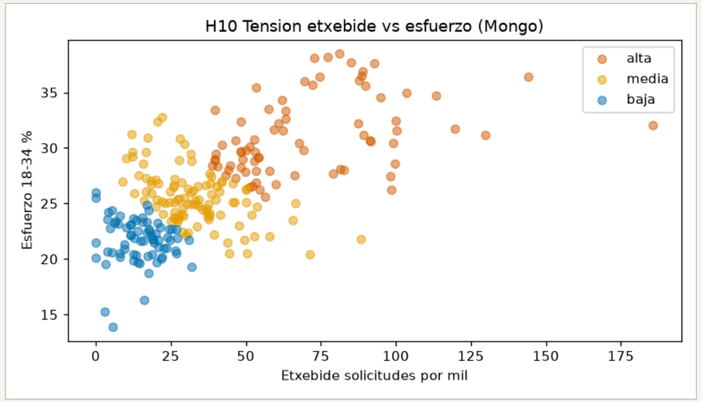
El titular aguanta. El orden fino, no.

Bootstrap 95 %	Bilbao 33,75-40,95 Getxo 27,54-31,77 Donostia 32,4-45,8
IDW 93	mediana 23,38 %
Temporal	misma mediana mensual (1.500 €), pero 80 vs 92,5 m²
Por m²	temporal +23,2 % (Fotocasa) · +13,7 % en el total
Demanda	Etxebide no sigue una recta con el precio

Los intervalos se solapan: no vendemos un podio, vendemos un umbral.



H8b · misma mediana €/mes, distinto €/m² (594 anuncios)



H10 · tensión social vs esfuerzo 18–34

Dos ramas sobre los mismos originales.

01
Fuentes
12 familias · API + scraping

→

02
raw inmutable
356 ficheros · SHA + .FROZEN

→

03
silver
182 ficheros · 40 CSV

→

04
Mongo
16 vivas · PyMongo

→

05
11 pipelines
CSV + PNG

CONSERVACIÓN

raw → Kafka → HDFS

manifiesto con SHA · consumidor que sube · nunca Kafka→Mongo

EXCEPCIÓN FIRMADA

HDFS solo raw

352 canónicos · procesados en local por indicación de la profesora · recuperación por SHA

Una orden. Y se puede reconstruir de cero.

```
python scripts/run_pipeline.py --fase silver,quality,gold
```

182/182
silver reconstruidos

53/53
gold byte a byte

38
nodos en el DAG

Limpieza en Mongo, no a mano

- `canonicalize_codigo_ine` — 5 dígitos, adiós al join por nombre
- `mark_nulls` — se marca, no se rellena
- `resolve_duplicates` — portal+id y huella cross-portal
- `convert_types` — Decimal128, int, bool

Lo que se lee junto se embebe. Lo que crece se referencia.

EMBEDDING

municipios

Se consulta entero y cambia poco: `demografia{}`, `empleo{}`, `demanda_social{}`.

REFERENCING

anuncios

Crece cada día: `ubicacion.codigo_ine → municipios._id`, con `equipamiento[]` e `historico_precios[]`.

No embebemos anuncios en el municipio: duplicaría datos y rompería el límite de 16 MB.

11 pipelines. Un índice. 594 → 1.

- **11 pipelines** con 8 etapas: `$match $group $lookup $unwind $project $sort $limit $addFields`
- **30 consultas** y CRUD completo con asserts
- Atomicidad de documento + índice único; transacción multidocumento justificada como innecesaria en standalone

FILTRO 20069 + LARGA + ≤1000	DOCS	CLAVES
Sin índice · COLLSCAN	594	0
Con ESR · IXSCAN	1	1

Índice `{ubicacion.codigo_ine, modalidad, precio_eur}` — orden ESR: igualdad, orden, rango.

No es una demo: falla cuando debe.

262

tests · 2 skipped

354

SHA del raw verificados

182

silver verificados

53

gold byte-idénticos

FAIL 07, visible: Aramaio 0,28 · Gaintza 1,45 · Usansolo 3,26 — paro cero en el INE con tasa no nula en Lanbide. Preferimos enseñarlo en rojo antes que imputarlo para que salga verde.

Gobernanza TODO OK · gate offline OK · FAIL 07 es un dato real, no un test roto.

Lo que sostenemos y lo que no.

Sostenemos

- Cuatro municipios con n≥30 y su esfuerzo con intervalo
- 40 de 159 por encima del 30 %
- Bilbao y Donostia cerca del 38 %

No sostenemos

- Ranking fino fuera de Tier A
- Emancipación municipal: solo CAE
- Precio donde no hay anuncio · procesados en HDFS

En la mayoría del territorio, justo; en las capitales, no; y en 188 municipios no lo sabemos.

Las 7 preguntas del Tema 8.

1. ¿Qué se consulta junto? Municipio + demografía + empleo + demanda social → embebido.

2. ¿Qué cambia? Anuncios y precios → colección propia.

3. ¿Arrays sin límite? `historico_precios[]` acotado; anuncios fuera.

4. ¿Fotografía histórica? Precio por fecha dentro del anuncio.

5. ¿Relaciones? Municipio 1:N anuncios; 1:1 alquiler/indicadores; N:M promociones.

6. ¿Campo común? `codigo_ine` a 5 dígitos, nunca el nombre.

7. ¿Tipos BSON? Decimal128 para dinero, int para conteos, date para fechas, 2dsphere para geo.

Transacción, réplica y shard key.

- Mongo local es **standalone**. La atomicidad de un documento no exige replica set.
- La transacción multidocumento sí lo exigiría; **no la forzamos** porque no hay operación que la necesite.
- Idempotencia real: upsert + índice único `(portal, id_anuncio)` + descarte por SHA.
- Shard key candidata: `codigo_ine`; a esta escala (594 anuncios) no se sharbea.

30 consultas y CRUD con asserts.

Consultas: igualdad, `dot notation`, `$all`, `$elemMatch`, `$size`, `$exists`, `$type`, regex, comparación, `$and`, `$or`, proyección, sort/limit, paginación.

CRUD: insert_one, insert_many, find, update_one, find_one_and_update, upsert, `$unset/$rename/$pull`, bulk_write, delete_one/many.

Cada operación se comprueba por código: `inserted_id`, `matched_count`, `modified_count`, `deleted_count`.

Nada se edita a mano en Mongo: la carga es staging + backup + rename atómico.

Los números, en crudo.

Datos

356 raw · 354 SHA

352 HDFS · 182 silver

40 CSV silver

594 anuncios (326/268)

64 municipios con anuncio

201 habitaciones / 9

5.040 Etxebide · 406 promos

Indicador

159 oficiales · 93 IDW

mediana 26,61 %

40/159 > 30 %

119 / 26 / 14

Tier A4 B3 C57 D188

60/252 con precio

Sistema

16 vivas + 14 backup

11 pipelines · 8 etapas

24 índices

262 tests · 2 skipped

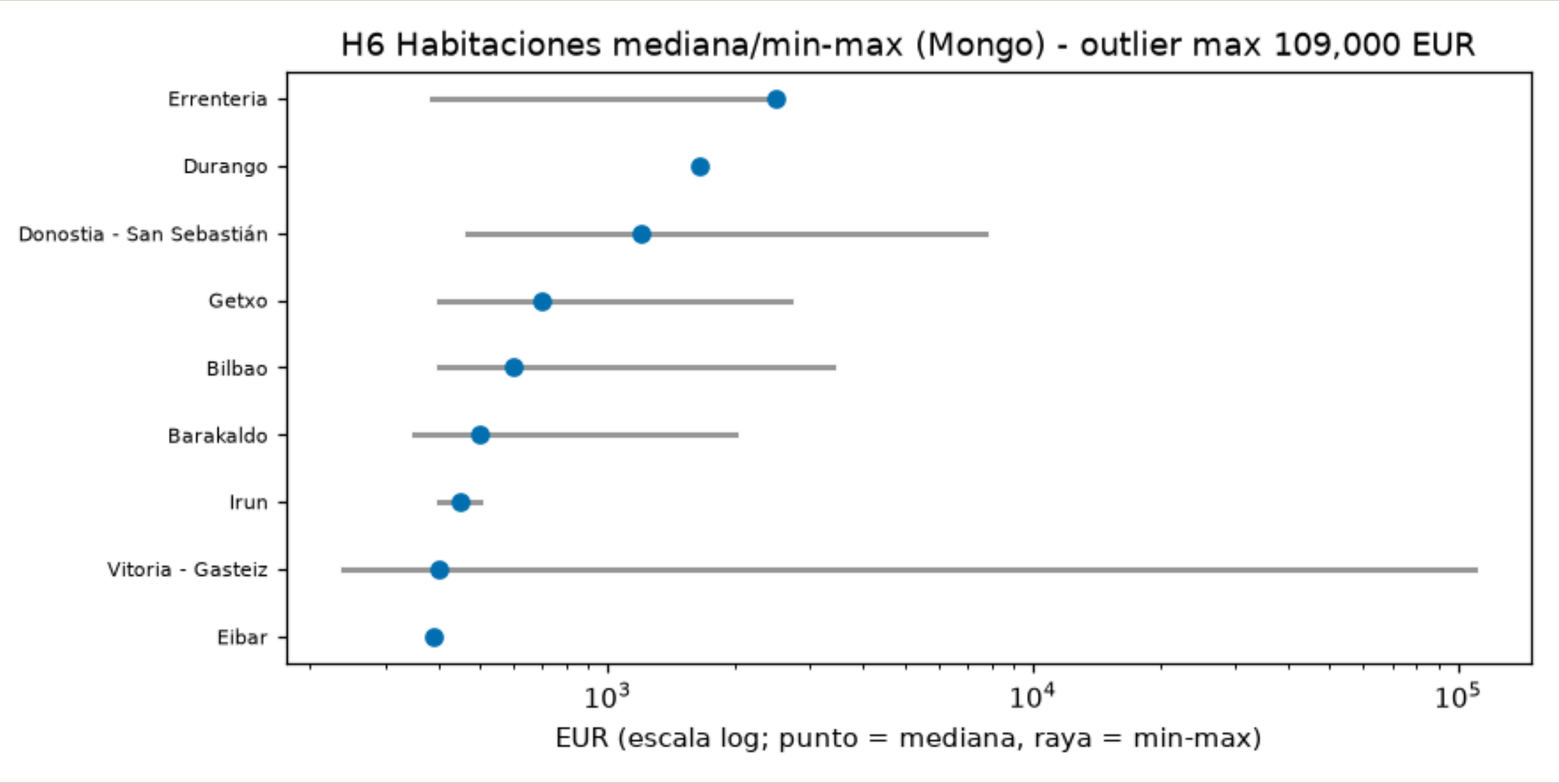
182/182 · 52/52

COLLSCAN 594 → IXSCAN 1

Lo que está verificado y lo que hoy no.

- **Verificado en vivo (2026-11-09):** 352 ficheros en HDFS, topic `vivienda_euskadi`, grupo `hdfs_centro`, 352 committed, lag 0.
- **Hoy:** el centro no es alcanzable; el gate offline verifica los 354 SHA locales y lo declara `PENDA-01`.
- **Recuperación:** `scripts/hdfs_recuperacion_un_fichero.py` descarga un raw y compara tamaño+SHA; 6 tests offline; pendiente corrida real.
- **Excepción:** procesados no se suben, por indicación de la profesora.

Habitación vs vivienda entera.



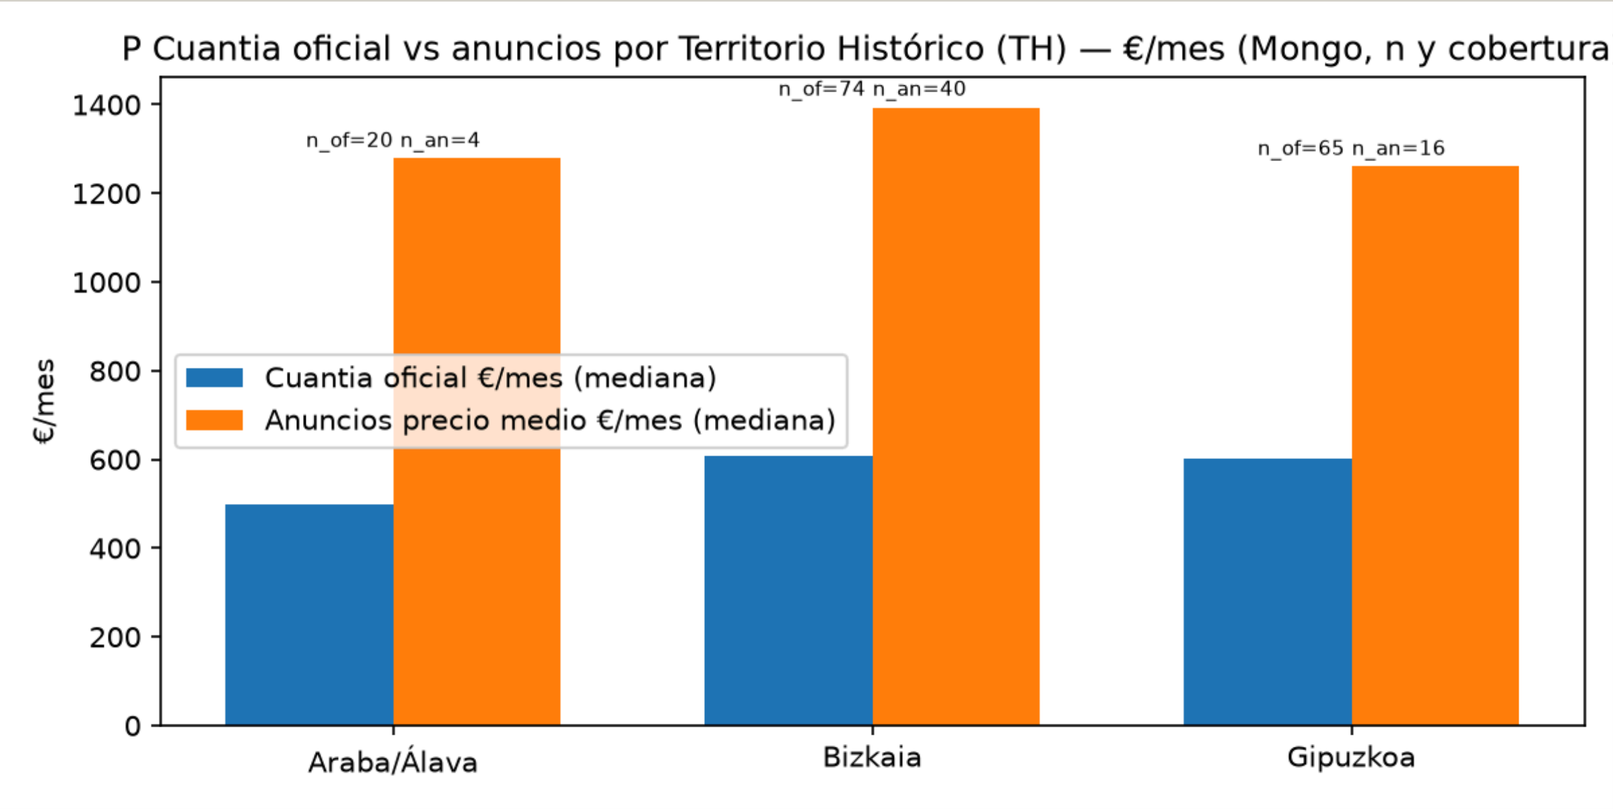
H6 · mediana con min-max y n_precio

201 anuncios en **9** municipios.

Solo Bilbao (96) y Donostia (66) sostienen comparación firme; el resto es indicativo.

No se agregan con vivienda entera: son productos distintos.

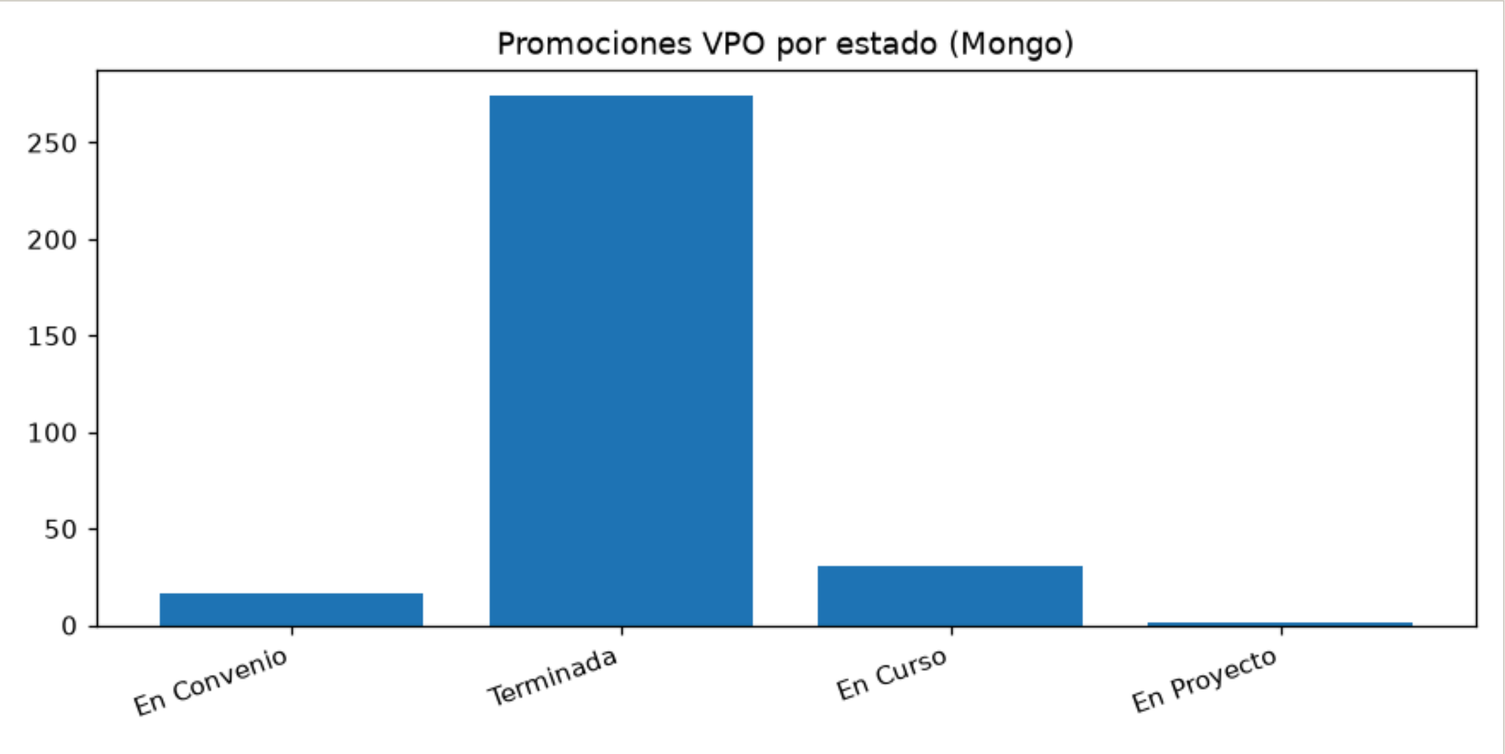
El alquiler oficial y el de anuncio no son lo mismo.



P · cuantía oficial vs anuncios por TH (n y cobertura)

El anuncio mide oferta publicada; el oficial, alquiler efectivo. Se usan para cosas distintas y no se mezclan en el indicador.

VPO: flujo, no stock.



C · promociones por estado y tipo

406 promociones en 77 municipios.

Flujo de terminadas: **251/252** municipios; Usansolo sin dato.

El stock no es público: no se inventa.