¿Puede una persona joven independizarse en Euskadi con su salario?

Auditoría empírica en dos capas: registro oficial (2024) y oferta publicada (2026) · 252 municipios

En la mayoría del territorio, justo.
En las capitales y en el mercado actual, no.

CAPA OFICIAL 2024 · EUSTAT / INE

26,61%

mediana del esfuerzo municipal · 159 municipios con alquiler oficial

40 / 159 superan el 30 %

Bilbao **37,69 %** · Donostia **38,17 %**

CAPA DE OFERTA 2026 · PORTALES

78,6%

mediana de las 50 medianas municipales

87,3 % mediana de los 287 anuncios

1.500 € alquiler mediano publicado

1.719 € salario joven ajustado

No son una serie temporal: son dos fotografías distintas. Primero auditamos el ancla oficial de 2024; después, el pulso real de la oferta en 2026.

Cómo medimos el esfuerzo de emancipación.

```
esfuerzo (%) = (alquiler mensual × 12) / renta joven estimada 18–34 × 100
```

Mediana, no media

El mercado inmobiliario es asimétrico; la mediana evita el sesgo de las viviendas de lujo.

Umbral crítico del 30 %

Estándar europeo de sobrecarga financiera; por encima del 35-40 % hay exclusión efectiva.

Cohorte 18-34 canónica

El tramo 16-29 queda como legacy (42,9 % de mediana, no comparable por baja actividad).

El indicador no es nuestro. Lo que aportamos es calcularlo municipal y decir dónde **no** se puede calcular.

La renta joven no está publicada por municipio y edad: la estimamos con las bandas de Eustat y la aplicamos a la renta municipal. Es un proxy, no un salario.

159 municipios con dato oficial. 93 sin muestra pública.

159

con alquiler oficial publicado (Eustat EMAL / SERPAVI)

93

sin publicación oficial: IDW comarcal, solo sensibilidad

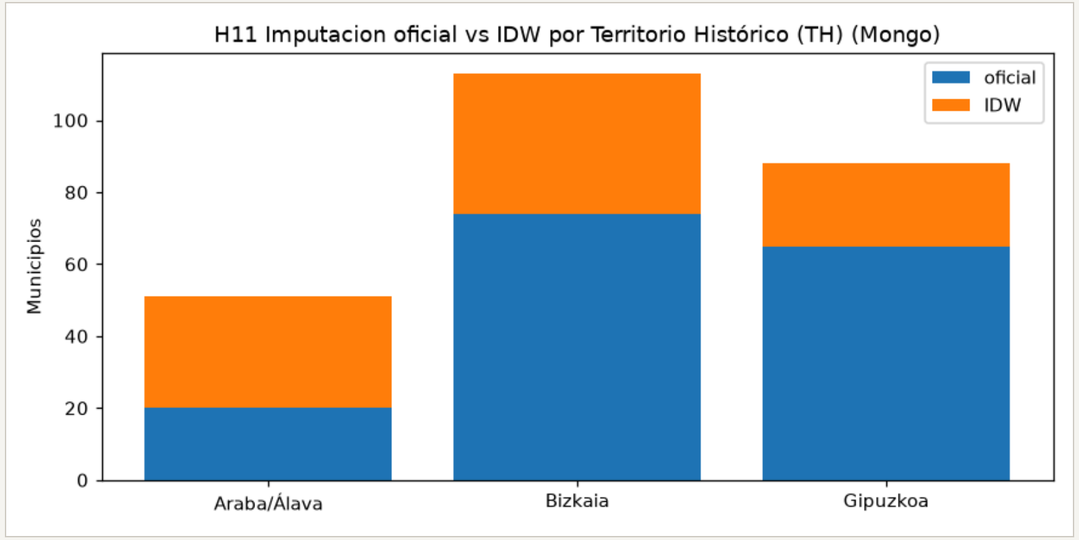
13

familias de fuentes oficiales y de mercado

355

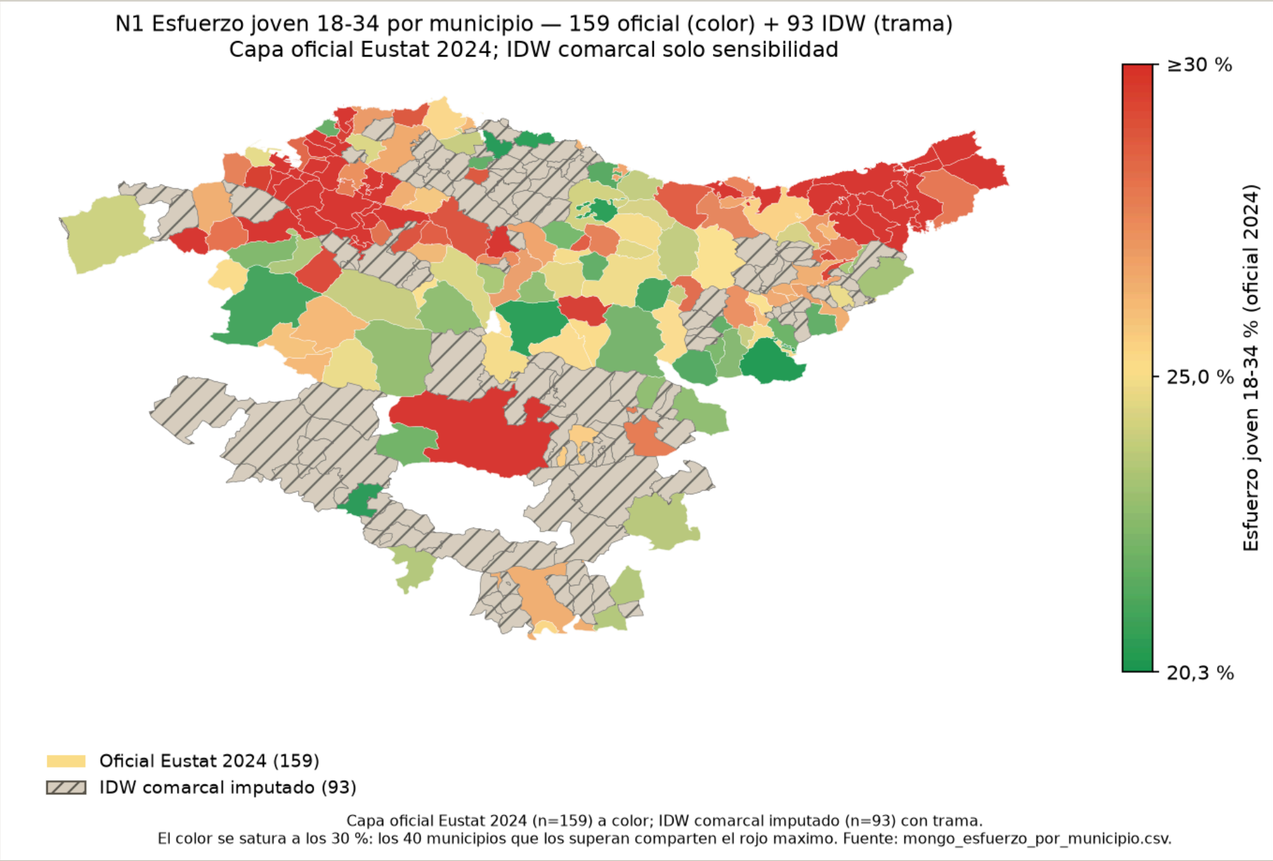
entradas de manifiesto SHA: 352 canónicos + 3 legado

- Eustat: alquiler municipal · INE Atlas: renta joven 18-34 · Lanbide/Udalmap: paro
- Etxebide: 5.040 solicitudes y 406 promociones VPO
- 353 objetos en HDFS: 352 canónicos + 1 manifiesto



H11 · 159 oficiales + 93 IDW por territorio · el IDW se muestra aparte

El esfuerzo tiene geografía clara.

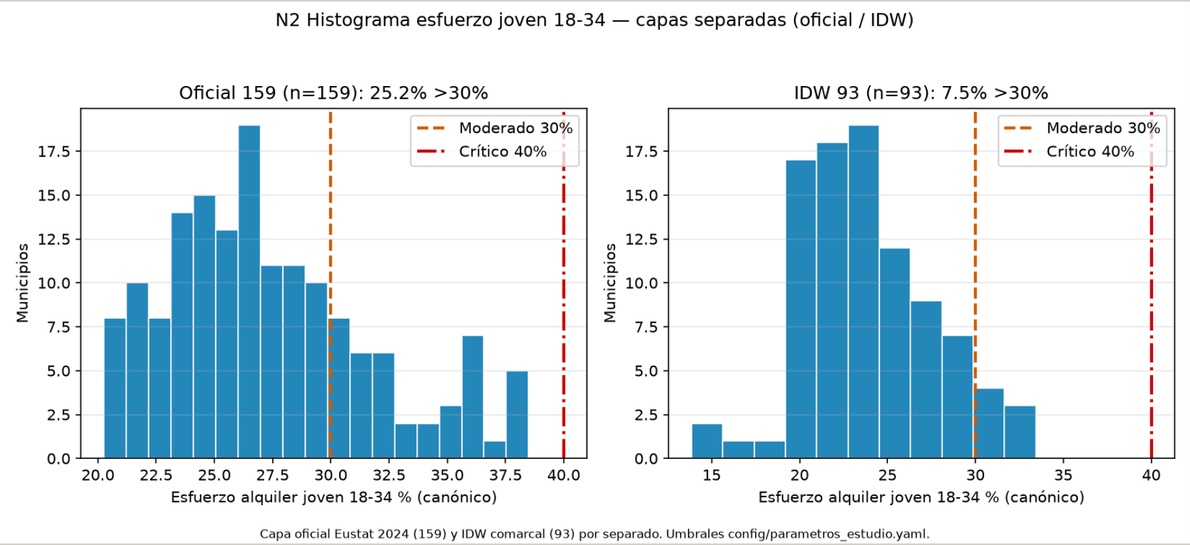


esfuerzo 18–34 · 159 oficial (color) + 93 IDW (trama) · el color se satura a los 30 %

- **Capitales y eje metropolitano:** Bilbao 37,69 %, Donostia 38,17 % y Vitoria-Gasteiz 33,37 % superan el límite saludable
- **Interior de Álava y rural:** por debajo del 30 %, pero con parque de alquiler muy reducido
- **Rigor visual:** la trama es IDW comarcal; nunca se mezcla con el dato oficial observado

data/resultados/mongo_esfuerzo_por_municipio.csv

No es un problema exclusivo de las capitales.



distribución del esfuerzo 18–34 · oficial 159 / IDW 93 · umbrales 30/40 %

119
municipios < 30 %

26
entre 30 % y 35 %

14
> 35 %

40 de 159 municipios (25,2 %) superan el 30 %. Si incluimos los 93 imputados por IDW, la mediana baja al 25,37 % y los que superan el 30 % son **47 de 252**: el problema se concentra donde vive la mayoría.

El dato oficial aguanta la auditoría externa.

Validación cruzada Eustat vs SERPAVI

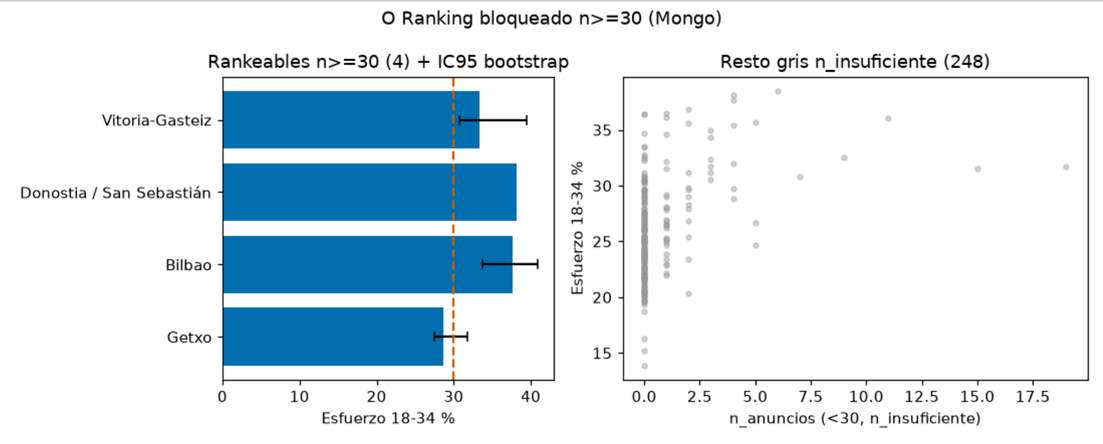
0,976
ratio SERPAVI / Eustat

0,979
correlación de Spearman

99,4%
dentro de ±25 %

€/M²·MES 2024	SERPAVI	EUSTAT
Bilbao	11,60	11,51
Donostia	14,90	13,99
Getxo	11,40	11,34

Valida el alquiler registrado de 2024, no el precio de anuncio de 2026. Si el oficial estuviera infrainflado, la diferencia con 2026 sería mayor: el sesgo iría en contra nuestra.



O · n≥30 = anuncios 2026 · IC de dispersión de precios, no del estimador Eustat

Bootstrap 95 %: Bilbao **33,75–40,95** · Getxo **27,54–31,77** · Donostia **32,4–45,8**. Se solapan: defendemos el cruce del 30 %, no un podio. El ancho mide dispersión de precios 2026 sobre el nivel 2024; **no** es el error del estimador Eustat.

De 843 anuncios crudos a 287 válidos.

843

anuncios crudos extraídos de 3 portales

594

vigentes tras deduplicación y cuarentena

326

vivienda completa con precio publicado

287

válidos: la muestra de la capa

45 en cuarentena fuera de Euskadi · **10** excluidos por el propio pipeline (900 m², 9.500 €) · **29** sin precio · **268** habitaciones/sin precio separados.

Amorebieta-Etxano y Laguardia caen a 0 anuncios: el mapa pasa de 52 a 50 municipios.

PORTAL	N	€/MES	€/M²
Fotocasa	152	1.432 €	15,36
Pisos.com	60	1.500 €	16,67
RealtyAPI	75	1.690 €	19,43

Medianas por portal. RealtyAPI es un **26 % más caro por m²**: no son tres cámaras iguales y se mide antes de mezclar.

Sin RealtyAPI (212 anuncios), la mediana de anuncios baja a **84,4 %**; la mediana municipal no se mueve: **78,6 %**.

La mediana municipal es 78,6 %. La de los 287 anuncios, 87,3 %.

78,6%

mediana de las 50 medianas municipales

87,3%

mediana de los 287 anuncios individuales

1.500€

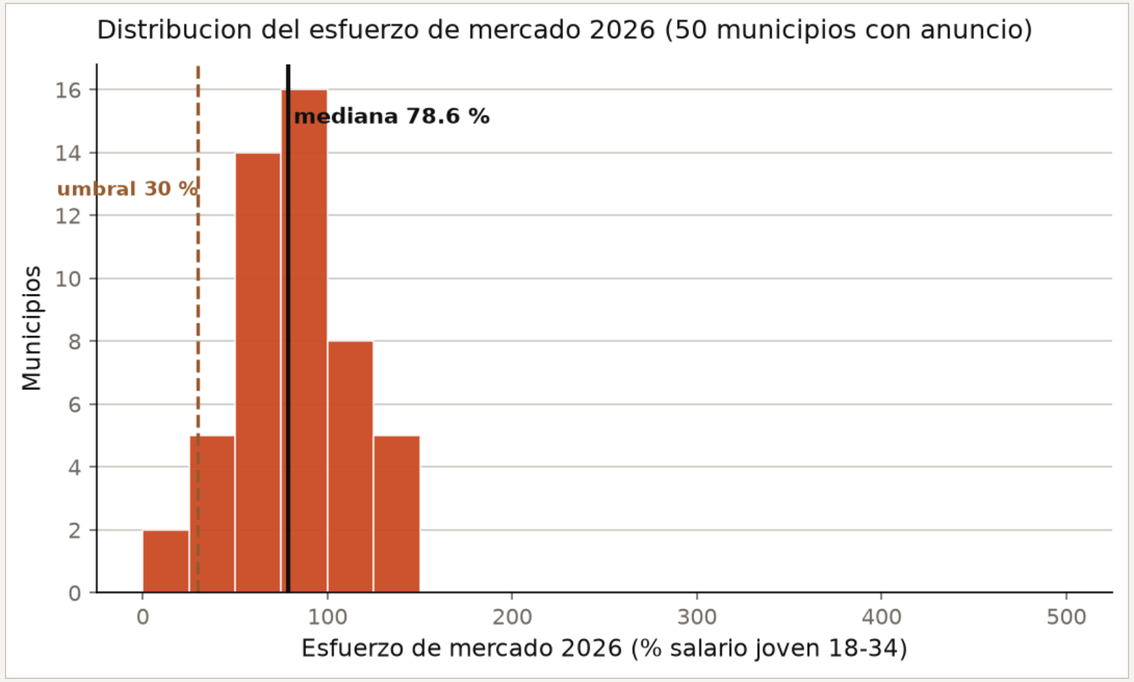
precio mediano del anuncio

1.719€

salario joven 18-34 ajustado a 2026

98,3 % de los 287 anuncios supera el 30 % del salario joven.

43 de los 50 municipios tienen n<5 y solo 4 tienen n≥30: el 78,6 % se defiende como nivel agregado, **no como mapa municipal**.



M26 · esfuerzo de mercado 2026 · 50 municipios con anuncio

Cubre el 20 % del territorio, pero el 71 % de los jóvenes.

50/252

municipios con anuncio válido: 19,8 % del territorio

71,2%

de la población de 18 a 34 años

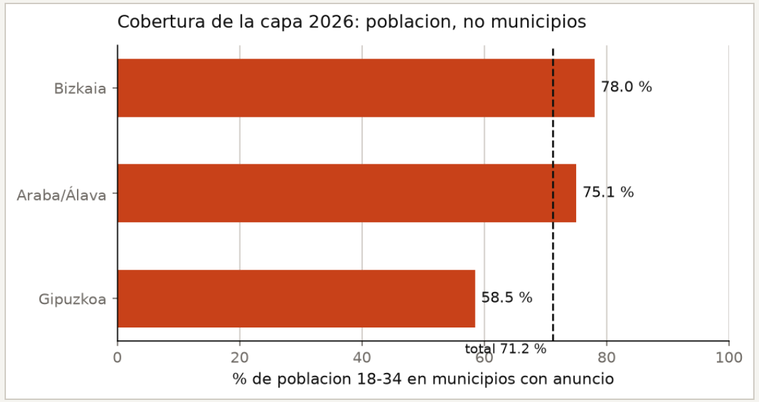
70,4%

de los anuncios, en 4 municipios

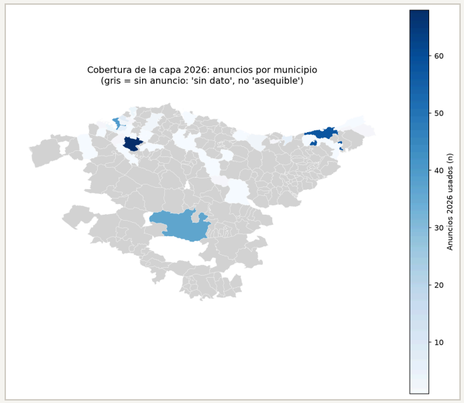
43

municipios con n<5: sin mediana publicada

El 78,6 % se defiende como nivel agregado, no como mapa municipal. El 70,4 % de los anuncios está en 4 municipios y 43 de los 50 no admiten mediana. El gris es falta de dato, no precio bueno.



M26 · % de población 18–34 cubierta · 50 municipios



n de anuncios por municipio · gris = sin dato

Solo cuatro municipios sostienen comparación firme (n ≥ 30).

MUNICIPIO	N 2026	ESFUERZO 2024	PRECIO 2026	ESFUERZO 2026	PARO 2024
Bilbao	68	37,69 %	1.687,50 €	98,19 %	9,71 %
Donostia / San Sebastián	58	38,17 %	2.000,00 €	116,37 %	5,82 %
Getxo	39	28,60 %	1.350,00 €	78,55 %	6,40 %
Vitoria-Gasteiz	37	33,37 %	1.300,00 €	75,64 %	8,89 %

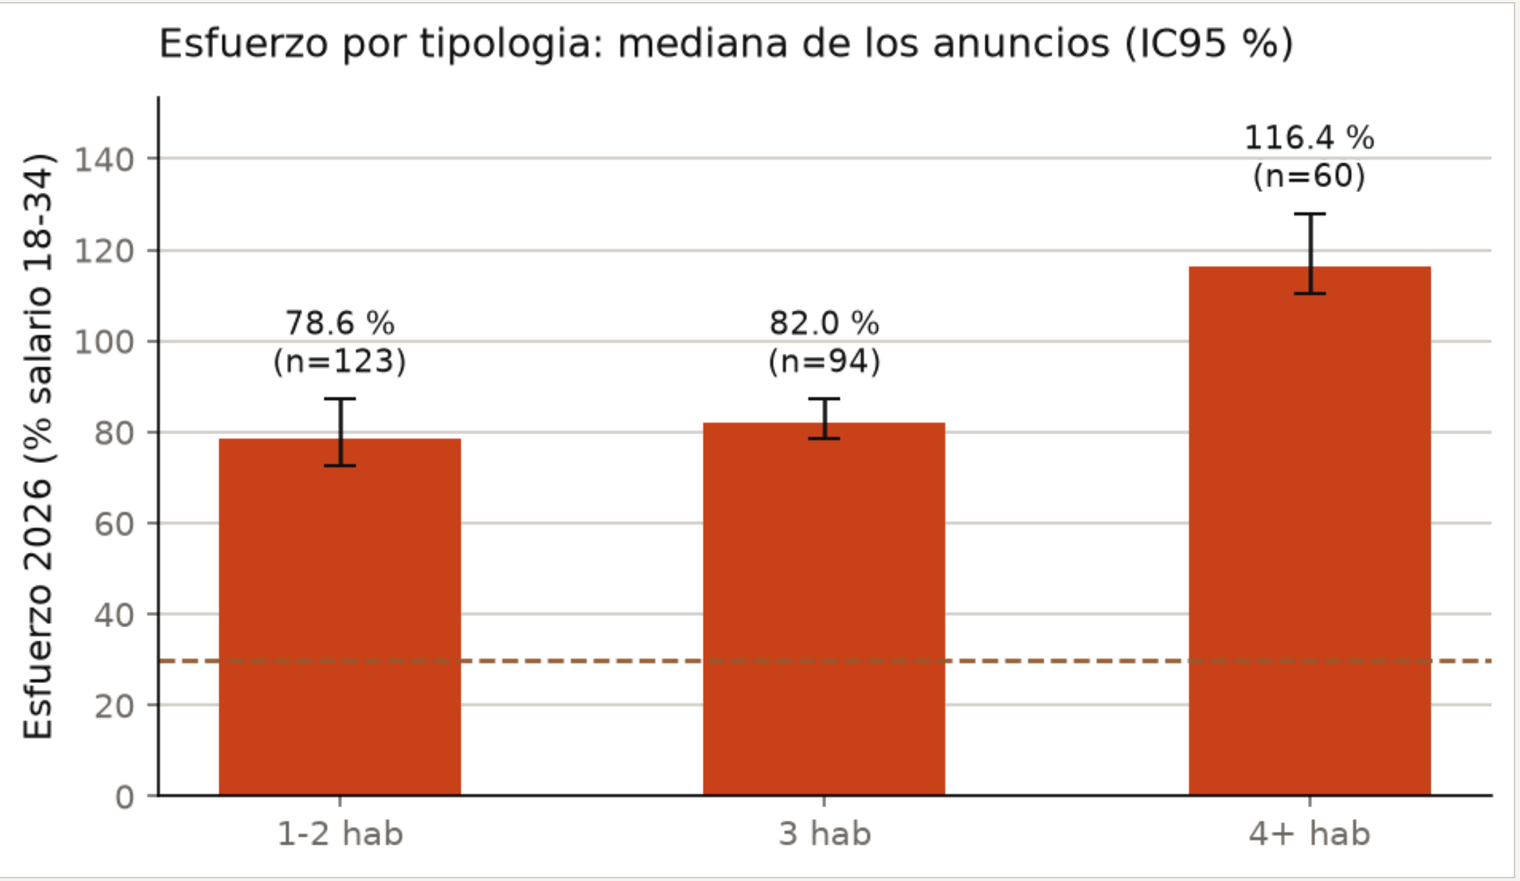
Cada columna va fechada porque viene de una capa distinta: el esfuerzo 2024 es alquiler oficial; el precio y el esfuerzo 2026 son anuncio; el paro es Udalmap 2024 general 16-64.

Getxo vs Vitoria: **2 anuncios** de diferencia. Sin podio 3º/4º.

Barakaldo, con **n=2**, no se lee como ranking: cualquier mediana municipal es ruido.

Es la única tabla donde las dos capas se tocan. Aquí sí hay muestra; en el resto del mapa, no.

Buscar piso grande dispara la barrera al 116 %.

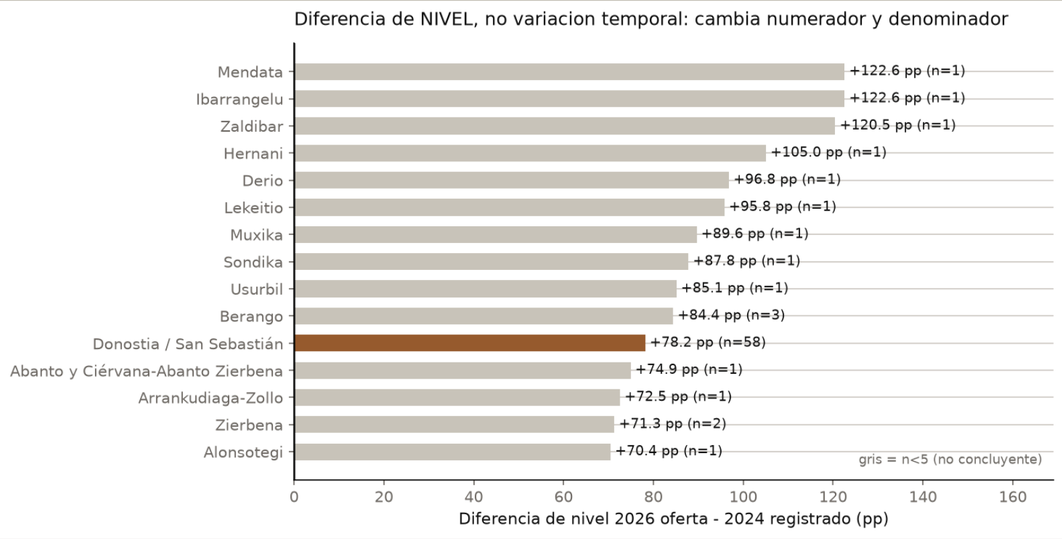


TIPO	N	ESFUERZO 18-34
1-2 hab	123	78,6 %
3 hab	94	82,0 %
4+ hab	60	116,4 %

Medianas a nivel de anuncio, no media de medianas municipales. El CSV municipal conserva el ponderado (80,4 / 85,2 / 120,1): los dos estimadores se publican.

M26 · mediana a nivel de anuncio con IC95 % bootstrap · 18–34 · 2026

Diferencia de nivel, no serie temporal.



M26 · diferencia en pp (18–34) · 15 mayores · gris = n<5, no concluyente

- Misma muestra y mismo denominador: **44,6 %** (2024 oficial) → **78,6 %** (2026 oferta)
- Con denominador canónico (renta joven 2024): **57,8 %** → el resto es denominador, no precio
- El precio de oferta multiplica por **1,88×** el alquiler registrado en el mismo municipio (**1,41×** en €/m²)
- Extremos: **+122,6 pp con n=1**; bajan Barakaldo (−15,2), Basauri (−12,8) y Eibar (−1,7), los tres con n≤2; en el gráfico van en gris. Solo Donostia en color (n=58).

No se restan como serie temporal: cambia el numerador (anuncio vs registrado) y el denominador.

Dos ramas, cinco capas y trazabilidad por SHA-256.

01
Fuentes
13 familias · API + scraping

→

02
Raw inmutable
355 SHA + .FROZEN · 352 canónicos + 3 legado

→

03
Silver
183 ficheros · 42 CSV a codigo_ine

→

04
MongoDB
17 vivas · PyMongo

→

05
Gold
53 artefactos · 24 CSV + 29 PNG

`python scripts/run_pipeline.py --fase silver,quality,gold` → 183/183 silver · 53/53 gold byte a byte · 40 nodos en el DAG.

CONSERVACIÓN

raw → Kafka → HDFS

productor lee manifiesto SHA → topic `vivienda_euskadi` → consumidor `hdfs_centro` → 353 objetos (352 canónicos + 1 manifiesto). Nunca Kafka → Mongo.

EXCEPCIÓN DECLARADA

HDFS solo raw

Silver y Gold se procesan en local por indicación expresa de la profesora. 352 canónicos + 1 manifiesto; recuperación por SHA.

Estado 2026-11-12: el NameNode responde y el inventario da 353 objetos; `OPEN` falla por DNS del datanode y Kafka acepta TCP pero no entrega metadata. La última evidencia funcional es v8: 352/352, lag 0. No se afirma como revalidado hoy.

Lo que se lee junto se embebe. Lo que crece se referencia.

EMBEDDING · municipios (252)

Se lee entero y cambia poco

`demografia{}`, `empleo{}`, `demanda_social{}`, `vivienda_contexto{}`, `transporte{}`.

REFERENCING · anuncios (594)

Crece cada día

`ubicacion.codigo_ine → municipios._id`, con `equipamiento[]` e `historico_precios[]`.

Clave natural: el `_id` de `municipios` **es** el código de 5 dígitos (`"48020"`), no un ObjectId. No hay un `codigo_ine` duplicado: el `_id` ya lo es.

17 colecciones vivas. Principales: municipios 252 · anuncios 594 · alquiler_municipal 252 · indicadores 252 · etxebide_solicitudes 5.040 · etxebide_promociones 406.

UN DOCUMENTO REAL · colección municipios

```
{
  "_id": "48020",              // codigo_ine
  "nombre_canonico": "Bilbao",
  "territorio": "Bizkaia",
  "demografia": {
    "poblacion_18_34_est": 73987,
    "renta_joven_estimada_18_34": 27063.9
  },
  "empleo": {
    "tasa_paro_lanbide_pct": 9.71
  },
  "demanda_social": {
    "etxebide_solicitudes_por_mil_2024": 84.98
  }
}
```

Tipos BSON: `Decimal128` para importes, `int32` para conteos, `Date` ISO para marcas temporales, `GeoJSON + 2dsphere` para consultas espaciales.

30 consultas y CRUD con asserts.

CRUD comprobado por código

`insert_one/many`, `find`, `update_one`, `find_one_and_update`, `upsert`, `$unset`, `$rename`, `$pull`, `bulk_write`, `delete_one/many`.

Cada operación comprueba `inserted_id`, `matched_count`, `modified_count` o `deleted_count`. Nada se edita a mano en Mongo: la carga es staging → backup → rename atómico.

30 consultas de negocio

Dot notation, `$all`, `$elemMatch`, `$size`, `$exists`, `$type`, regex, comparación, `$and/$or`, proyección, `sort/limit` y paginación determinista.

CONSULTA REAL · campo anidado + array + 2 condiciones

```
db.anuncios.find(
    {
        "ubicacion.codigo_ine": "48020",
        "equipamiento": {
            "$all": ["ascensor", "terraza"]
        },
        "precio_eur": {"$lte": 1200},
    },
    {
        "_id": 0,
        "precio_eur": 1,
        "ubicacion.municipio": 1,
    },
).sort({"precio_eur": 1}).limit(5)
```

Cumple los cinco tipos de la rúbrica: filtro, comparación, array, proyección y orden. La misma batería se ejecuta en `analysis/mongo_queries.py`.

11 pipelines. Un índice. 594 → 1.

- **11 pipelines** con 8 etapas: `$match $group $lookup $unwind $project $sort $limit $addFields`
- `$lookup` cruza `anuncios` y `municipios` por `codigo_ine`; `$group` calcula medianas y conteos
- Preguntas del reto: esfuerzo, VPO, accesibilidad, habitaciones, tensión social

Idempotencia: upsert + índice único `(portal, id_anuncio)` + descarte por SHA.

FILTRO 20069 + LARGA + ≤1.000 €	DOCS	CLAVES
Sin índice · COLLSCAN	594	0
Con ESR · IXSCAN	1	1

Índice `{ubicacion.codigo_ine: 1, modalidad: 1, precio_eur: 1}` — orden **ESR**: igualdad, orden, rango.

25 índices en total; 5 en `anuncios`: ESR, `2dsphere`, único `(portal, id_anuncio)` y multikey `equipamiento`.

Consistencia sin sobreingeniería.

01 · ATOMICIDAD

Documento, no transacción

En standalone, cada escritura sobre un documento es atómica. No forzamos transacciones multidocumento (exigirían Replica Set) porque el modelo embebido evita actualizar varias colecciones en una operación crítica.

02 · IDEMPOTENCIA

Tres barreras

(a) descarte en ingesta por hash SHA-256; (b) índice único compuesto `(portal, id_anuncio)`; (c) `update_one(upsert=True)` + carga atómica por `renameCollection`. Re-ejecutar 10 veces deja los mismos 594 documentos.

03 · ESCALABILIDAD

Shard key razonada

A escala actual (594 anuncios / 252 municipios) un nodo standalone sobra. Si escalara a nivel estatal con histórico diario, la shard key óptima sería `{ubicacion.codigo_ine: 1, _id: 1}`: alta cardinalidad y aislamiento geográfico.

La consistencia se demuestra con código: `tests/test_mongo_consistencia.py` comprueba la operación atómica y la idempotencia de la carga.

No es una demo: los tests fallan cuando el dato miente.

287

tests · 285 pasan · 2 skipped

355

SHA del raw verificados

183

silver validados en esquema y tipos

53

gold reproducibles byte a byte

FAIL 07, visible: Aramaio 0,28 · Gaintza 1,45 · Usansolo 3,26 — paro cero en el INE con tasa no nula en Lanbide. Preferimos enseñarlo en rojo antes que imputarlo para que salga verde.

Gobernanza TODO OK · gate offline OK · FAIL 07 es un dato real, no un test roto. 183/183 silver y 53/53 gold reconstruidos desde cero.

Qué dicen juntas las dos capas.

DIMENSIÓN	CAPA OFICIAL 2024	CAPA DE OFERTA 2026	LECTURA CONJUNTA
Cobertura	159 oficiales + 93 IDW	50 municipios (71,2 % de jóvenes)	188 Tier D sin anuncio: sin dato, no asequible
Alquiler mediano	708 € en los 50 (p25–p75: 620–744)	1.350 € mediana de medianas · 1.500 € mediana de anuncios	La oferta nueva multiplica por 1,88
Esfuerzo 18-34	26,61 % (40/159 > 30 %)	78,6 % municipal · 87,3 % anuncio	En capitales, 75–116 %: inviable en solitario
Uso analítico	Diagnóstico estructural	Barrera de acceso actual	No se restan como serie temporal

La diferencia de 2024 a 2026 es de nivel, no de serie: cambia la fuente del numerador y el denominador. Cuando se igualan, el salto es 44,6 % → 78,6 %; con el denominador canónico, 57,8 %.

Lo que sostenemos, lo que no y qué nos tumbaría.

Sostenemos con evidencia

- Cuatro municipios con n≥30 y su esfuerzo 2024/2026: Bilbao 37,69/98,19; Donostia 38,17/116,37; Getxo 28,60/78,55; Vitoria 33,37/75,64
- 40 de 159 municipios por encima del 30 % en 2024
- El 87,3 % como nivel de la capa 2026 (287 anuncios), no como mapa municipal

No sostenemos

- Ranking fino fuera de Tier A: 43 municipios con n<5
- Emancipación municipal: solo tenemos CAE
- Precio donde no hay anuncio: 188 municipios en gris
- Serie temporal 2024 → 2026: son capas distintas

Nos tumbaría: una fuente independiente con n≥30 que, en la misma ventana, mueva más de un 10 % el precio de Bilbao, Donostia, Getxo o Vitoria; o encontrar un piso de los 45 en cuarentena que sí esté en Euskadi.

Excepción declarada: HDFS guarda solo raw (352 canónicos + 1 manifiesto); los procesados se quedan en local por indicación de la profesora. Con más datos, lo primero sería subir la muestra de los 57 Tier C y separar temporal de larga.

Conclusión.

En la mayoría del territorio, justo; en las capitales, no; en el mercado de entrada actual, prohibitivo; y en 188 municipios no lo sabemos.

Gracias. Abrimos el código, los datos y el CSV de cada cifra de esta charla.

Las 7 preguntas del Tema 8.

1. ¿Qué se consulta junto? Municipio + demografía + empleo + demanda social → embebido.

2. ¿Qué cambia? Anuncios y precios → colección propia.

3. ¿Arrays sin límite? `historico_precios[]` acotado; anuncios fuera.

4. ¿Fotografía histórica? Precio por fecha dentro del anuncio.

5. ¿Relaciones? Municipio 1:N anuncios; 1:1 alquiler/indicadores; N:M promociones.

6. ¿Campo común? `codigo_ine` a 5 dígitos; en `municipios` es el `_id`.

7. ¿Tipos BSON? Decimal128 para dinero, int32 para conteos, Date para fechas, 2dsphere para geo.

Los números, en crudo.

Datos

355 SHA · 357 ficheros en disco

352 canónicos + 3 legado

353 objetos en HDFS (352 + 1 manifiesto)

183 silver · 42 CSV

594 anuncios (326 larga + 268 temporal)

64 municipios con anuncio

287 válidos en 50 municipios

201 habitaciones / 9 municipios

5.040 solicitudes · 406 promociones

Indicador

159 oficiales + 93 IDW

mediana 26,61 % (159)

40/159 > 30 % · 119/26/14

25,37 % global · 47/252 > 30 %

78,6 % municipal (50)

87,3 % anuncio (287)

1.350 € mediana de medianas

1.500 € mediana de anuncios

Tier A4 B3 C57 D188

Sistema

17 vivas + 15 backup = 32

11 pipelines · 8 etapas · 30 consultas

25 índices · 5 en anuncios

287 tests (285 pasan, 2 skip)

183/183 · 53/53

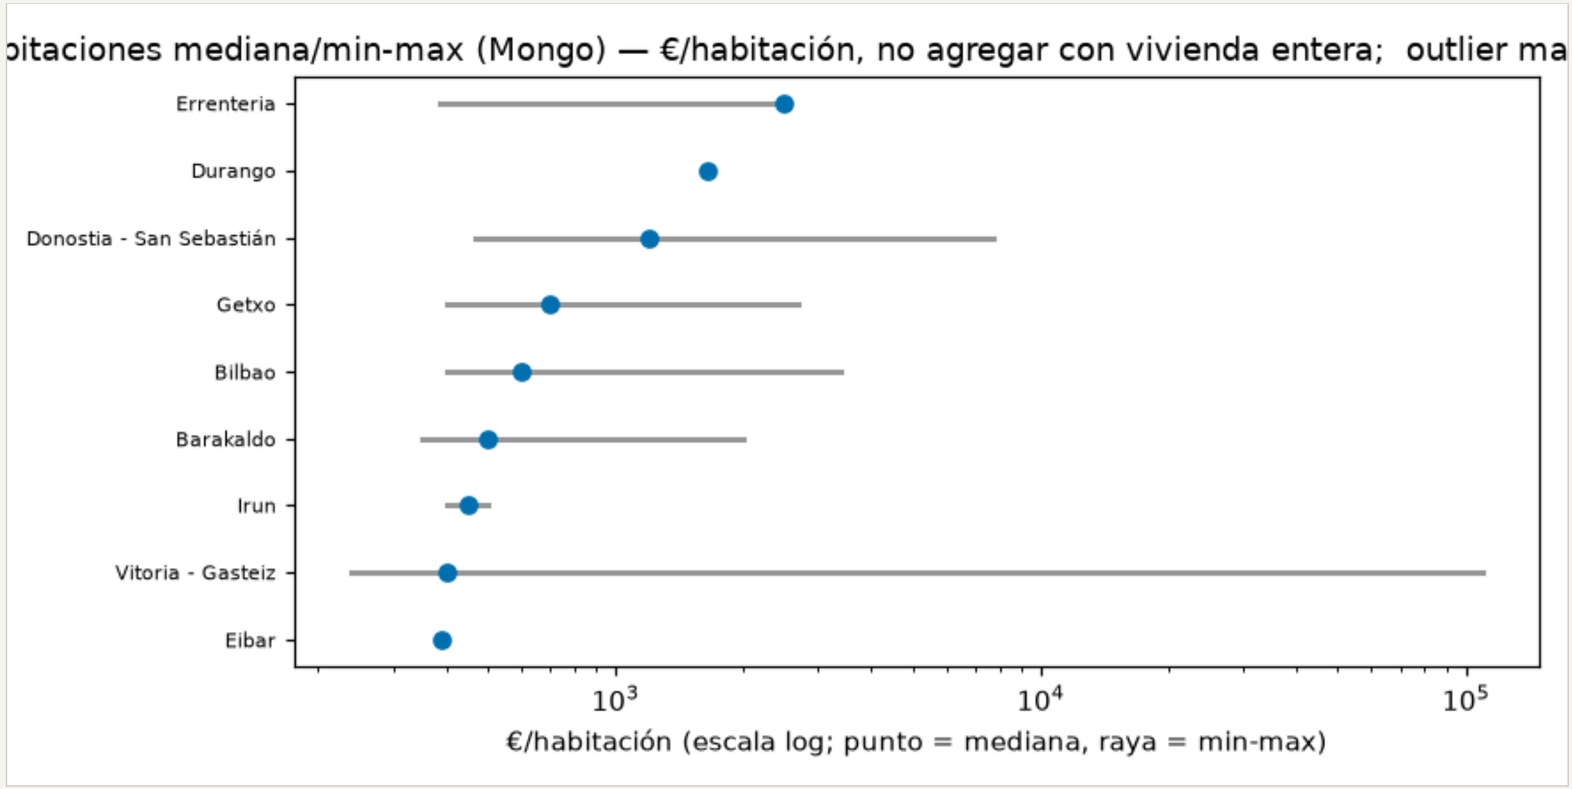
COLLSCAN 594 → IXSCAN 1

40 nodos en el DAG

Lo que está verificado y lo que hoy no.

- **Inventario HDFS (2026-11-12):** 353 objetos, 895.597.901 B; `/data/raw` con 202 hijos; `/data/procesado` responde 404 por la excepción declarada.
- **Recuperación:** `scripts/hdfs_recuperacion_un_fichero.py` coteja tamaño y SHA, pero el `OPEN` de WebHDFS falla por DNS del datanode (`hadoop-worker*.tartangalh.eus`) y el script aún no escribe destino (`--out`). No se presenta como recuperación cerrada.
- **Kafka:** TCP 9092 responde, pero `list_topics` da `NodeNotReadyError` y no hay metadata. La evidencia funcional es v8: topic `vivienda_euskadi`, 352/352, lag 0.
- **Excepción:** los procesados no se suben; solo los 352 canónicos + el manifiesto. Es una decisión declarada, no un olvido.

Habitación vs vivienda entera.



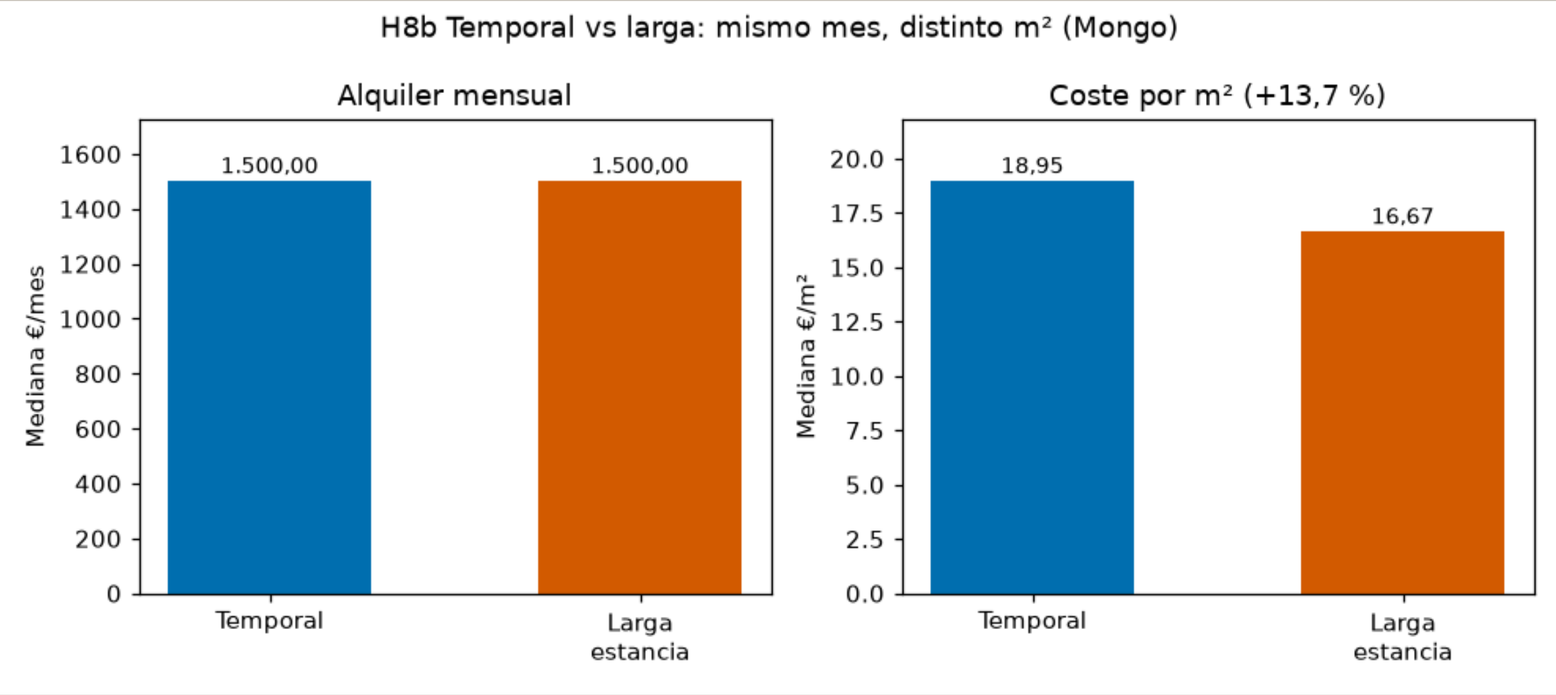
H6 · €/habitación, mediana con min-max y n_precio

201 anuncios en **9** municipios.

Solo Bilbao (96) y Donostia (66) sostienen comparación firme; el resto es indicativo.

No se agregan con vivienda entera: son productos distintos.

Temporal y larga estancia: mismo alquiler, distinto metro.



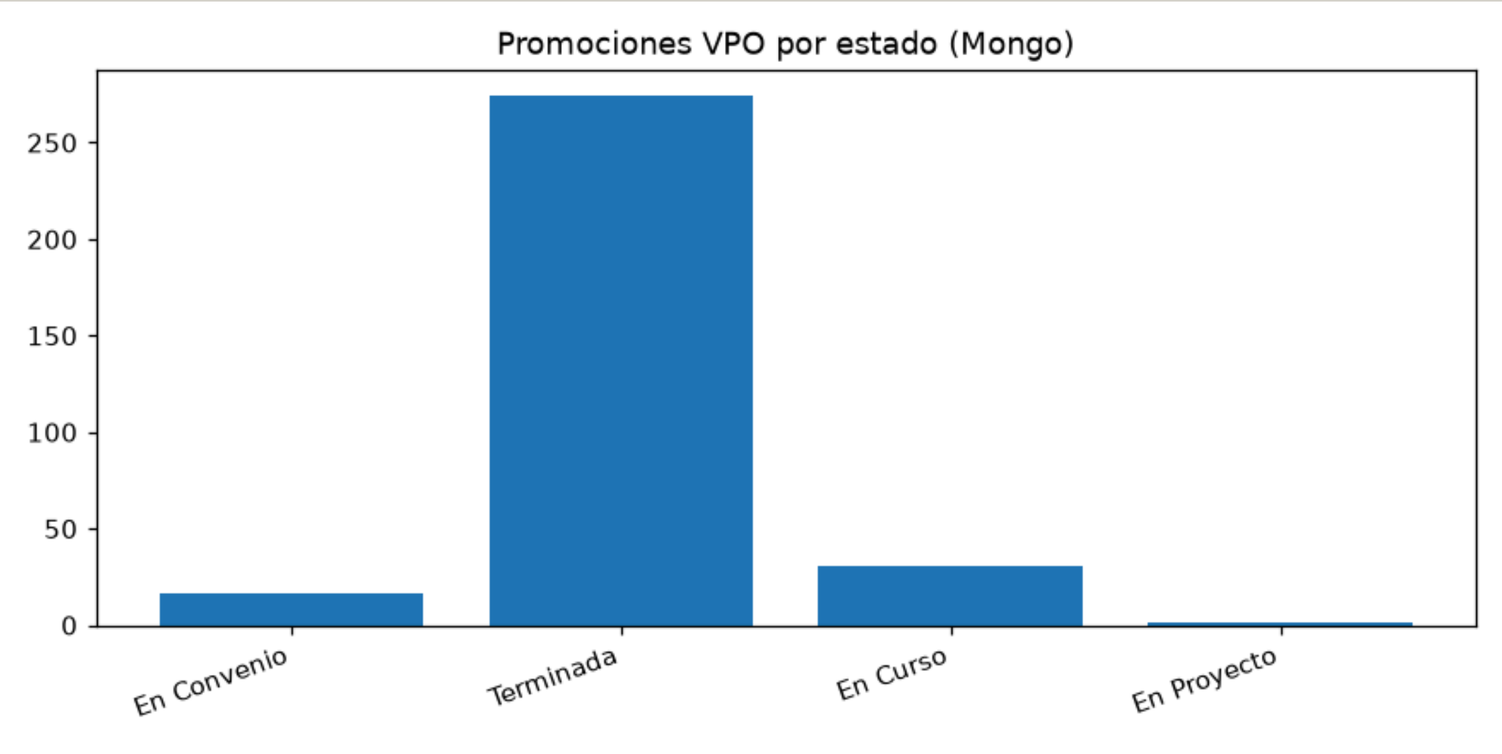
H8b · mediana €/mes y €/m² por modalidad (594 anuncios)

Misma **mediana mensual (1.500 €)**, pero el temporal es más pequeño: **80 vs 92,5 m²**.

Por m², el temporal es **+23,2 %** en Fotocasa y **+13,7 %** en el total (18,95 vs 16,67 €/m²).

Por eso no se mezclan las modalidades en el indicador.

VPO: flujo, no stock.



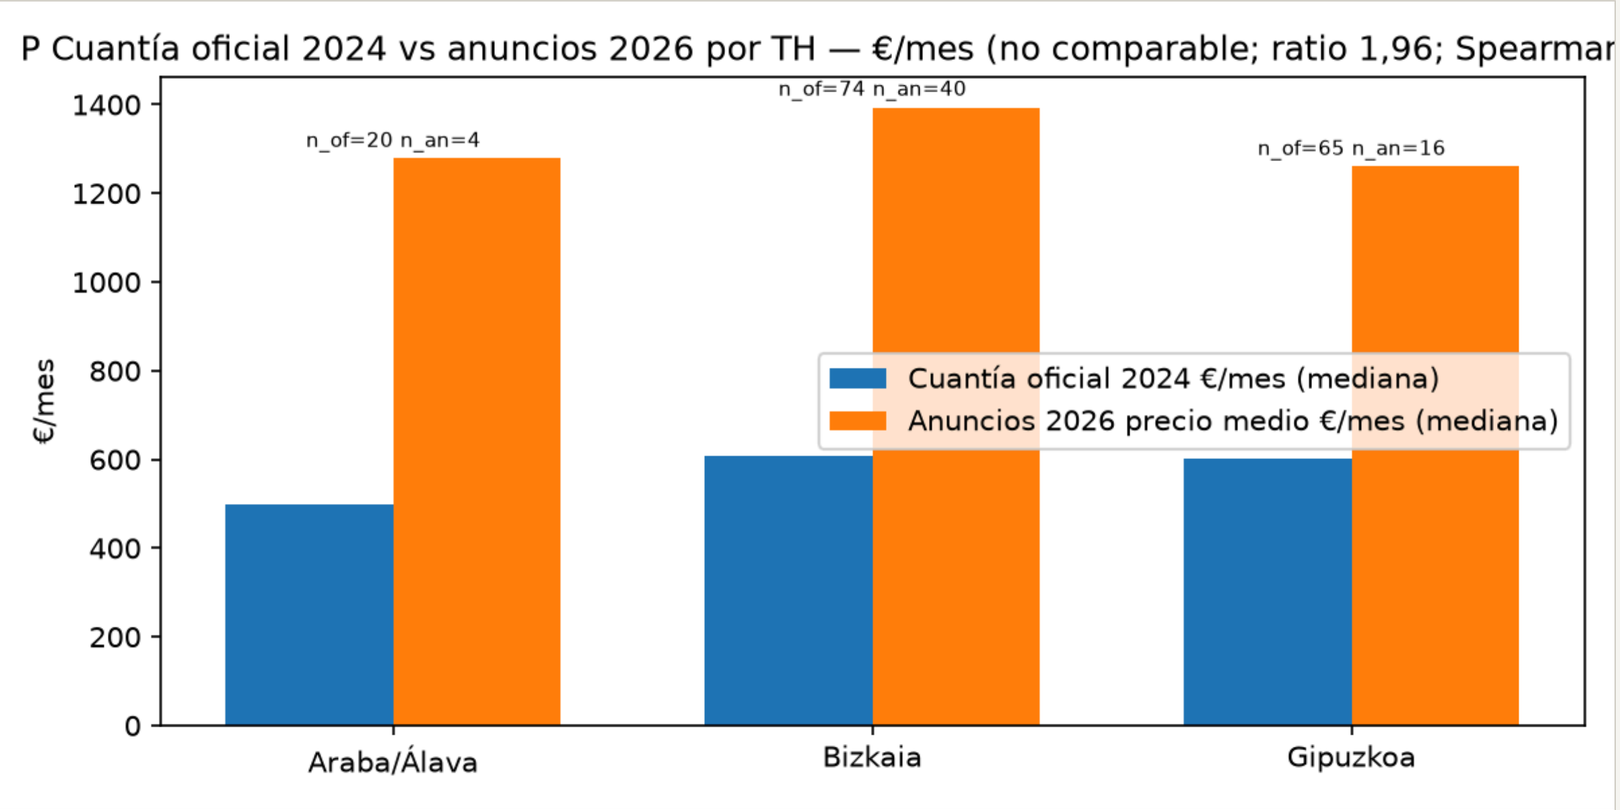
C · promociones por estado y tipo

406 promociones en 77 municipios.

Flujo de terminadas: **251/252** municipios; Usansolo sin dato.

El stock no es público: no se inventa.

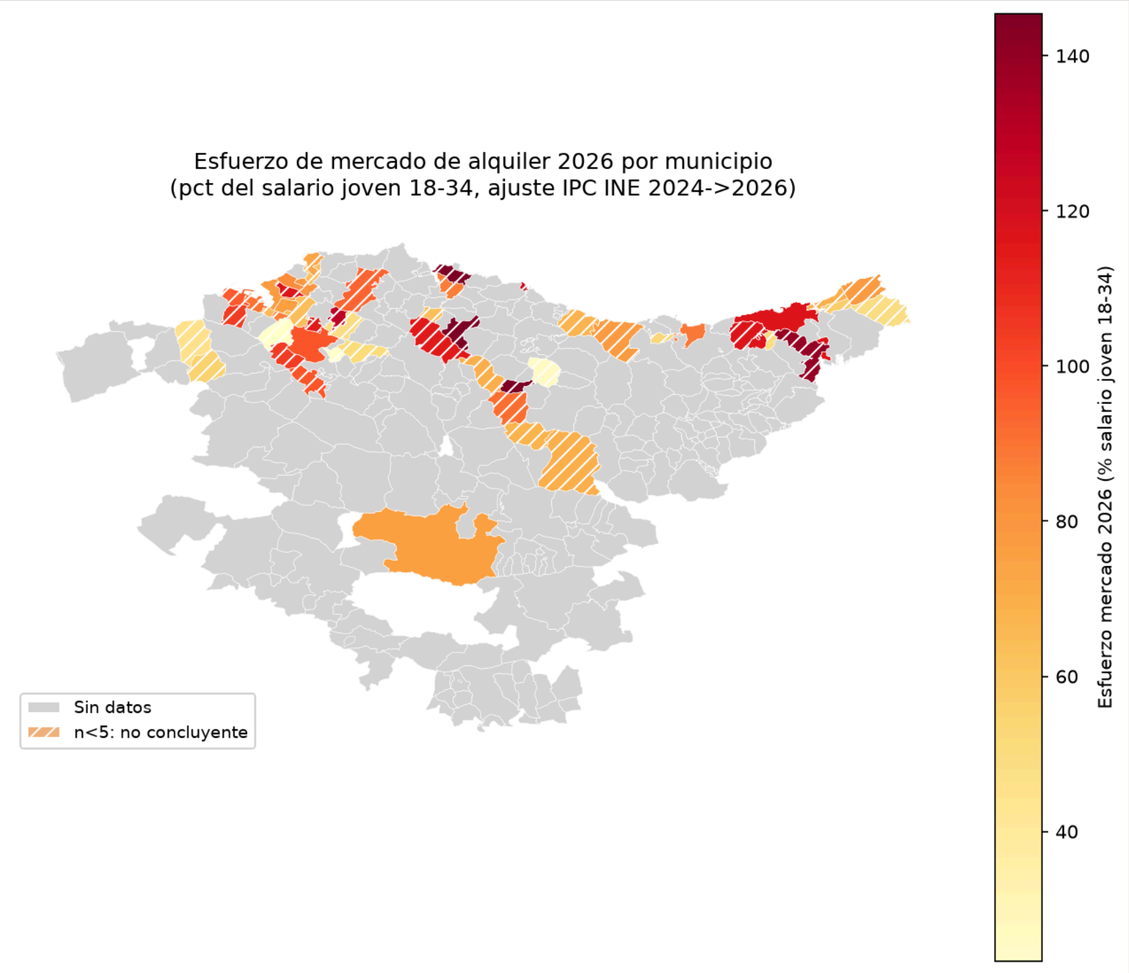
El alquiler oficial y el de anuncio no son lo mismo.



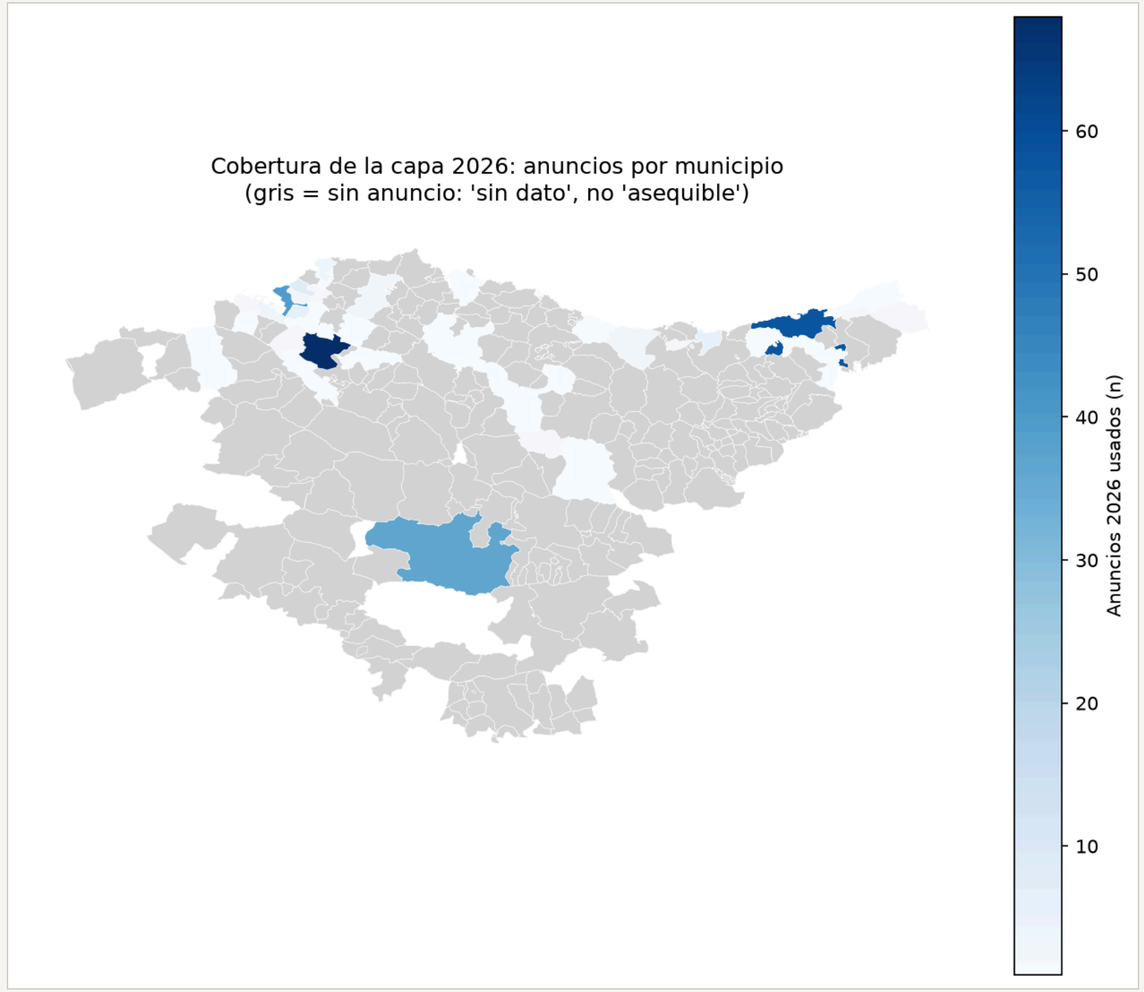
P · cuantía oficial 2024 vs anuncios 2026 por TH — ratio 1,96; Spearman 0,18

El anuncio mide oferta publicada; el oficial, alquiler efectivo. Se usan para cosas distintas y no se mezclan en el indicador. Que no correlacionen no invalida ninguna de las dos capas: obliga a declarar la unidad.

Cuánto cuesta y cuánto sabemos.



esfuerzo de mercado 2026 por municipio · gris = sin anuncio



n de anuncios por municipio · 50 con dato

La misma geografía del esfuerzo canónico, leída sobre precio publicado. Y la segunda capa dice dónde ese color no existe: 50 municipios, 71,2 % de los jóvenes, 43 sin mediana.